

# Integración Monte Carlo

Roberto Vásquez Martínez

Universidad de Guanajuato

November 25, 2019

# Contenidos

- 1 Introducción
- 2 Fundamentos Teóricos
- 3 Convergencia
- 4 Error en la estimación
- 5 Reducción de Varianza
- 6 Algoritmo VEGAS
- 7 VEGAS vs PLANE Monte Carlo
- 8 Ejemplos en varias variables
- 9 Conclusiones
- 10 Referencias

- Los métodos Monte Carlo son técnicas numéricas las cuales se basan en muestreos aleatorios para aproximar sus resultados.

# Antecedentes Históricos

- Los métodos Monte Carlo son técnicas numéricas las cuales se basan en muestreos aleatorios para aproximar sus resultados.
- El término “Monte Carlo” se origina en *Los Alamos National Laboratory* a finales de la década de 1940's durante el desarrollo de la bomba atómica.

- Los métodos Monte Carlo son técnicas numéricas las cuales se basan en muestreos aleatorios para aproximar sus resultados.
- El término “Monte Carlo” se origina en *Los Alamos National Laboratory* a finales de la década de 1940's durante el desarrollo de la bomba atómica.
- El algoritmo VEGAS fue propuesto por Peter Lepage en 1978 como una mejora a las estimaciones del Método Monte Carlo usual

# El problema

Queremos hallar

$$F = \int_a^b f(x) dx.$$

# El problema

Queremos hallar

$$F = \int_a^b f(x) dx.$$


Podemos aproximar esta integral através de

$$F_n = (b - a) \frac{1}{n} \sum_{i=1}^n f(X_i)$$

En general el estimador se calcula con un muestreo uniforme en la región de integración.

## Ejemplo: Estimación de $\pi$

Integramos la función  $f(x) = \sqrt{1 - x^2}$  en el intervalo  $[-1, 1]$ .





Notemos que el valor esperado de  $F_n$  es en efecto  $F$ . De la **Ley Fuerte de los grades números** se tiene que

$$P\left[\lim_{n \rightarrow \infty} F_n = F\right] = 1,$$

por lo que en el límite podemos garantizar que tenemos el resultado correcto.

Si  $\sigma^2 = \text{Var}(f(X))$  entonces por el **Teorema Central del Límite** para un nivel de confianza de  $\delta = n\sigma$  se tiene que

$$\lim_{N \rightarrow \infty} P\left(-n\frac{\sigma}{\sqrt{N}} < F_N - F < n\frac{\sigma}{\sqrt{N}}\right) = \int_{-n}^n \frac{e^{-\frac{1}{2}t^2}}{\sqrt{2\pi}}$$

Si  $\sigma^2 = \text{Var}(f(X))$  entonces por el **Teorema Central del Límite** para un nivel de confianza de  $\delta = n\sigma$  se tiene que

$$\lim_{N \rightarrow \infty} P\left(-n \frac{\sigma}{\sqrt{N}} < F_N - F < n \frac{\sigma}{\sqrt{N}}\right) = \int_{-n}^n \frac{e^{-\frac{1}{2}t^2}}{\sqrt{2\pi}}$$

Considerando una desviación típica

$$|F_N - F| \approx \frac{\sigma}{\sqrt{N}}.$$

- El factor  $\frac{1}{\sqrt{N}}$  no puede ser del todo satisfactorio.

- El factor  $\frac{1}{\sqrt{N}}$  no puede ser del todo satisfactorio.
- Podemos realizar mejoras a este método logrando una reducción de el factor  $\sigma^2$ , es decir, una **reducción de varianza**

# Muestreo por importancia

Consideremos el cambio de variable

$$\int f dV = \int \frac{f}{g} g dV = \int h g dV,$$

con  $g$  una densidad de probabilidad. Así podemos integrar  $f$  a partir de integrar  $h$  considerando una muestra generada a partir de la densidad  $g$ .

# Muestreo por importancia

Consideremos el cambio de variable

$$\int f dV = \int \frac{f}{g} g dV = \int h g dV,$$

con  $g$  una densidad de probabilidad. Así podemos integrar  $f$  a partir de integrar  $h$  considerando una muestra generada a partir de la densidad  $g$ .

## Observación.

Lo que sugerimos es en lugar de generar una colección de variables aleatorias con distribución uniforme es generar estas variables aleatorias a partir de una densidad  $g$  más apropiada.

# Muestreo por importancia

El estimador en este caso es

$$H_N = \frac{1}{N} \sum_{i=1}^N \frac{f(x_i)}{g(x_i)}$$



# Muestreo por importancia

El estimador en este caso es

$$H_N = \frac{1}{N} \sum_{i=1}^N \frac{f(x_i)}{g(x_i)}$$

El  $g$  ideal

Se puede probar que el  $g$  óptimo es  $g(x) = \frac{|f(x)|}{\int |f(x)| dV}$ , es decir,  $g \propto |f|$ .

Este método se basa en partir la región de integración y estimar la integral en cada región con el Método Monte Carlo usual.

# VEGAS para una variable

- Fue propuesto por Peter Lepage en 1978.

# VEGAS para una variable

- Fue propuesto por Peter Lepage en 1978.
- Este método combina muestreo estratificado y muestro por importancia para obtener una mejor aproximación al problema original.

Compararemos el desempeño de VEGAS y Plane Monte Carlo al calcular la integral de las siguientes funciones

$$f_1(x) = \sqrt{1 - x^2},$$

$$f_2(x) = \frac{1}{x},$$

$$f_3(x) = \tan x,$$

en los intervalos  $[-1, 1]$ ,  $[1, e]$  y  $[0, \frac{\pi}{4}]$ , respectivamente.

Sabemos que los valores reales en cada caso son

$$\int_{-1}^1 f_1(x) = \sqrt{1-x^2} = \frac{\pi}{2} \approx 1.57079,$$

$$\int_1^e f_2(x) = 1,$$

$$\int_0^{\pi/4} f_3(x) = \frac{\log(2)}{2} \approx 0.346573,$$

# Resultados PLANE Monte Carlo

Los resultados que obtuvimos a partir del método PLANE Monte Carlo fueron:

El valor de  $\pi/2$  es: 1.56965

El error en la estimacion es: 0.00115055

El valor de  $\ln(e)$  es: 1.00264

El error en la estimacion es: 0.00263956

El valor de  $\ln(2)/2$  es: 0.346916

El error en la estimacion fue de: 0.000342268

Los resultados que obtuvimos a partir de nuestra implementación del algoritmo VEGAS fueron:

El valor de  $\pi/2$ : 1.5708

El error en la estimación fue:  $1.0673e-06$

El valor de  $\ln(e)$  es: 0.99999

El error en la estimación fue:  $5.2191e-06$

El valor de  $\ln(2)/2$  es: 0.34658

El error en la estimación fue:  $5.291e-06$



- VEGAS obtiene mejores estimaciones que PLANE Monte Carlo con menos evaluaciones.

- VEGAS obtiene mejores estimaciones que PLANE Monte Carlo con menos evaluaciones.
- PLANE Monte Carlo necesita un gran número de muestras para obtener una aproximación aceptable.

- VEGAS obtiene mejores estimaciones que PLANE Monte Carlo con menos evaluaciones.
- PLANE Monte Carlo necesita un gran número de muestras para obtener una aproximación aceptable.
- Cada uno de estos métodos se puede generalizar a más variables y el error en la estimación no depende de la dimensión del integrando.

# Monte Carlo en varias variables

Implementamos PLANE Monte Carlo para calcular la integral de una función en varias variables.

A manera de ejemplo calculamos el volumen de la esfera unitaria y el toro de radio mayor 2 y radio menor 1.

```
El volumen de la esfera unitaria es: 4.19437
```

```
El error es: 0.00399527
```

```
El volumen del toro de radio mayor 2 y radio menor 1 es:
```

```
El error es: 0.0834826.
```

- El valor del error siempre se puede calcular.

# Puntos a favor

- El valor del error siempre se puede calcular.
- La función a integrar no necesita ser continua.

- El valor del error siempre se puede calcular.
- La función a integrar no necesita ser continua.
- La tasa de convergencia no depende de la dimensión del integrando.

- El valor del error siempre se puede calcular.
- La función a integrar no necesita ser continua.
- La tasa de convergencia no depende de la dimensión del integrando.
- EL algoritmo VEGAS es adaptativo, es decir, concentra su atención en las regiones de mayor aporte a la integral.



- PLANE Monte Carlo necesita de muchas evaluaciones para obtener un buen resultado.

- PLANE Monte Carlo necesita de muchas evaluaciones para obtener un buen resultado.
- VEGAS en varias dimensiones supone que la la densidad óptima se puede factorizar en las densidades marginales lo que puede provocar un gran error en la estimación para algunas funciones.

- PLANE Monte Carlo necesita de muchas evaluaciones para obtener un buen resultado.
- VEGAS en varias dimensiones supone que la la densidad óptima se puede factorizar en las densidades marginales lo que puede provocar un gran error en la estimación para algunas funciones.
- Hay mejores algoritmos para una variable.

- PLANE Monte Carlo necesita de muchas evaluaciones para obtener un buen resultado.
- VEGAS en varias dimensiones supone que la la densidad óptima se puede factorizar en las densidades marginales lo que puede provocar un gran error en la estimación para algunas funciones.
- Hay mejores algoritmos para una variable.
- Los métodos Monte Carlo suponen que la esperanza respectiva es finita, lo que no siempre es válido.



Lepage, G. (1978).

"New Algorithm for Adaptive Multidimensional Integration".  
*Journal of Computational Physics*, vol.27:pp 192–203.



Owen, A. B. (2013).

*Monte Carlo theory, methods and examples.*



Press W., T. S. (2007).

*Numerical Recipes in C.*  
Cambridge Press.

The End